

Machine Learning (Aprendizaje automático de máquina)

"ML"

Horario

Martes y Jueves 3:00 pm - 5:00 pm

Salón

Sala Turing (Torre 2 piso 3)

Evaluación

4 proyectos (20% cada uno)

Talleres (20%)

Atención

Martes 2:00 pm - 3:00 pm

Jueves 11:00 am - 12:00 m

(o a través del correo electrónico)

Yiby Morales

yiby.morales@urosario.edu.co

Edificio Cabal Piso 4, Of 408

Temas, bibliografía etc



En la guía de asignatura (e-avlas)

Observaciones sobre talleres y proyectos

- Se dará importancia a las intuiciones, comentarios, análisis, reflexiones, conclusiones, etc provenientes de los procesos llevados a cabo en los trabajos, más que al código mismo.
- Se espera y asume originalidad en la estructura, estilo y razón de ser del código, así como en los aspectos mencionados en el ítem anterior.
- La entrega tardía (salvo en casos justificados de acuerdo al reglamento académico) de los trabajos repercute en la calificación de los mismos

Humans are Hooked

Machines are Learning



How do you combine machine learning and physics-based modeling

Hoy: ☐ Aprendizaje supervisado y no supervisado

☐ Tipos de variables

☐ Tipos de problemas

☐ Aprendizaje supervisado: Generalidad

☐ Notación

☐ Funciones de pérdida

Aprendizaje automático

Algoritmos que a partir de la experiencia
mejoran su desempeño en una tarea

Aprendizaje automático

Algoritmos que a partir de la experiencia
mejoran su desempeño en una tarea

Procesar
información
de los datos

Ej. Predecir una
Variable

Conjunto de datos

Texto de correos electrónicos

Datos de pacientes dados de alta
de hospitalización

Texto de comentarios en facebook

Datos de películas de Netflix

Datos de clientes de una empresa

Datos de procedimientos y servicios
médicos adquiridos por cada paciente
en una EPS

Conjunto de datos	Ejemplo tarea
Texto de correos electrónicos	
Datos de pacientes dados de alta de hospitalización	
Texto de comentarios en facebook	
Datos de películas de Netflix	
Datos de clientes de una empresa	
Datos de procedimientos y servicios médicos adquiridos por cada paciente en una EPS	

Conjunto de datos	Ejemplo tarea
Texto de correos electrónicos	Determinar si es spam o no
Datos de pacientes dados de alta de hospitalización	Determinar si regresará al hospital antes de seis semanas
Texto de comentarios en facebook	Determinar si son positivos o no
Datos de películas de Netflix	Determinar relaciones entre las películas Ej. Si te gusto — te puede gustar —
Datos de clientes de una empresa	Determinar grupos de interés
Datos de procedimientos y servicios médicos adquiridos por cada paciente en una EPS	Predecir los gastos totales de la EPS por paciente en el siguiente bimestre

Aprendizaje supervisado

Enfoque del aprendizaje automático que parte de unos datos etiquetados esto es: hay una variable objetivo (que puede ser de diferentes tipos)


registros
(filas)

[illegible]

Variable objetivo (o etiqueta)
Conocida


Aprendizaje supervisado

Enfoque del aprendizaje automático que parte de unos datos etiquetados esto es: hay una variable objetivo (que puede ser de diferentes tipos)



El modelo aprende con base en los datos proporcionados y sus etiquetas.

La tarea será predecir dicha variable para nuevos registros



La tarea del modelo
es determinar estos valores


lo mejor posible

Métricas (Mais
adelante!)

Aprendizaje no supervisado

Algoritmos de ML que parten de datos sin etiqueta o variable objetivo. Estos algoritmos inspeccionan los datos y son rapaces, por ejemplo, de agruparlos.

Los algoritmos de aprendizaje no supervisado descubren patrones ocultos en los datos sin necesidad de intervención humana



Variable
objetivo



Conjunto de datos	Ejemplo tarea	Supervisado?	Etiqueta
Texto de correos electrónicos	Determinar si es spam o no		
Datos de pacientes dados de alta de hospitalización	Determinar si regresará al hospital antes de seis semanas		
Texto de comentarios en Facebook	Determinar si son positivos o no		
Datos de películas de Netflix	Determinar relaciones entre las películas Ej. Si te gusto <u> </u> te puede gustar <u> </u>		
Datos de clientes de una empresa	Determinar grupos de interés		
Datos de procedimientos y servicios médicos adquiridos por cada paciente en una EPS	Predicir Los gastos totales de la EPS por paciente en el siguiente bimestre		

Variable
objetivo



Conjunto de datos	Ejemplo tarea	Supervisado?	Etiqueta
Texto de correos electrónicos	Determinar si es spam o no	✓	sí/no
Datos de pacientes dados de alta de hospitalización	Determinar si regresará al hospital antes de seis semanas	✓	sí/no
Texto de comentarios en facebook	Determinar si son positivos o no	✓	+/-
Datos de películas de Netflix	Determinar relaciones entre las películas Ej. Si te gusto <u> </u> te puede gustar <u> </u>	X	NA
Datos de clientes de una empresa	Determinar grupos de interés	X	NA
Datos de procedimientos y servicios médicos adquiridos por cada paciente en una EPS	Predicir Los gastos totales de la EPS por paciente en el siguiente bimestre	✓	Costo \$

Tipos de variables

Cuantitativas

- Numéricas
- Cercanía numérica
representa cercanía
en "naturaleza"

Cualitativas

- Pueden ser numéricas, pero
generalmente denotan categorías
- Dos tipos

Nominal

Sin orden

Ordinal

Con orden

Tipos de problema

Supervisado

Clasificación

La variable
es categórica

Clasificación
Binaria

Clasificación
Multiclase

Regresión

La variable
es cuantitativa,
un número real


No supervisado

Agrupamiento
(Clustering)

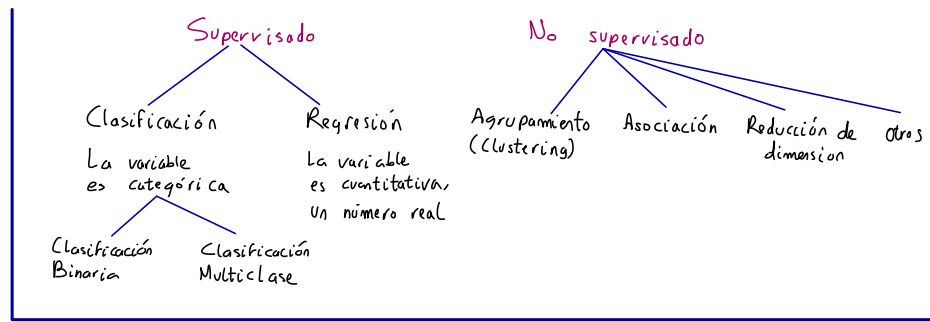
Asociación

Reducción de
dimension

Otros



Conjunto de datos	Ejemplo tarea	Supervisado?	Etiqueta	Tipo de problema
Texto de correos electrónicos	Determinar si es spam o no	✓	sí/no	
Datos de pacientes dados de alta de hospitalización	Determinar si regresará al hospital antes de seis semanas	✓	sí/no	
Texto de comentarios en Facebook	Determinar si son positivos o no	✓	+/-	
Datos de películas de Netflix	Determinar relaciones entre las películas Ej. Si te gusta — te puede gustar —	X	NA	
Datos de clientes de una empresa	Determinar grupos de interés	X	NA	
Datos de procedimientos y servicios médicos adquiridos por cada paciente en una EPS	Predicir los gastos totales de la EPS por paciente en el siguiente bimestre	✓	Costo \$	



Conjunto de datos	Ejemplo tarea	Supervisado?	Etiqueta	Tipo de problema
Texto de correos electrónicos	Determinar si es spam o no	✓	sí/no	Clas. Binaria
Datos de pacientes dados de alta de hospitalización	Determinar si regresará al hospital antes de seis semanas	✓	sí/no	Clas. Binaria
Texto de comentarios en Facebook	Determinar si son positivos o no	✓	+/-	Clas. Binaria
Datos de películas de Netflix	Determinar relaciones entre las películas Ej. Si te gusta — te puede gustar —	X	NA	Asociación
Datos de clientes de una empresa	Determinar grupos de interés	X	NA	Clustering
Datos de procedimientos y servicios médicos adquiridos por cada paciente en una EPS	Predicir los gastos totales de la EPS por paciente en el siguiente bimestre	✓	Costo \$	Regresión


A partir de ahora y hasta nuevo anuncio...

Aprendizaje Supervisado

Programación clásica



ML



Notación

D : Conjunto de datos observados

$$D = \{ (\vec{x}_1, y_1), \dots, (\vec{x}_n, y_n) \} \subseteq X \times Y$$

\downarrow email \searrow {si, no}

$(\vec{x}_i, y_i) \sim P \rightarrow$ Proviene de una distribución desconocida

Notación

D : Conjunto de datos observados

$$D = \{ (\vec{x}_1, y_1), \dots, (\vec{x}_n, y_n) \} \subseteq X \times Y$$

\downarrow
email \rightarrow {sí, no}

$(\vec{x}_i, y_i) \sim P \rightarrow$ Proviene de una distribución desconocida

¿Dónde vive (x_i, y_i) ? ¿Qué es X y Y ?

$$X = \mathbb{R}^d \quad Y = \mathbb{R}, \mathbb{R}^k$$

\vec{x}_i : i -ésimo dato en la muestra

$$y_i \in Y$$

Clasificación binaria ej.

$$Y = \{0, 1\}$$

$$Y = \{-1, 1\}$$

Clasificación multiclase ej.

$$Y = \{1, \dots, k\}$$

Regresión

$$Y = \mathbb{R}$$

Ejemplos

1) Datos de pacientes

$$\vec{X}_i = \begin{bmatrix} 62 \\ 183 \\ \vdots \end{bmatrix} \begin{array}{l} \text{Edad} \\ \text{Estatura} \end{array}$$


2) Correos electrónicos

Codificar palabras ?

$$\begin{bmatrix} 0 \\ \vdots \\ 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} \begin{array}{l} a \\ abajo \\ \vdots \\ saludos \\ zum \end{array}$$

3. Imágenes



Píxeles



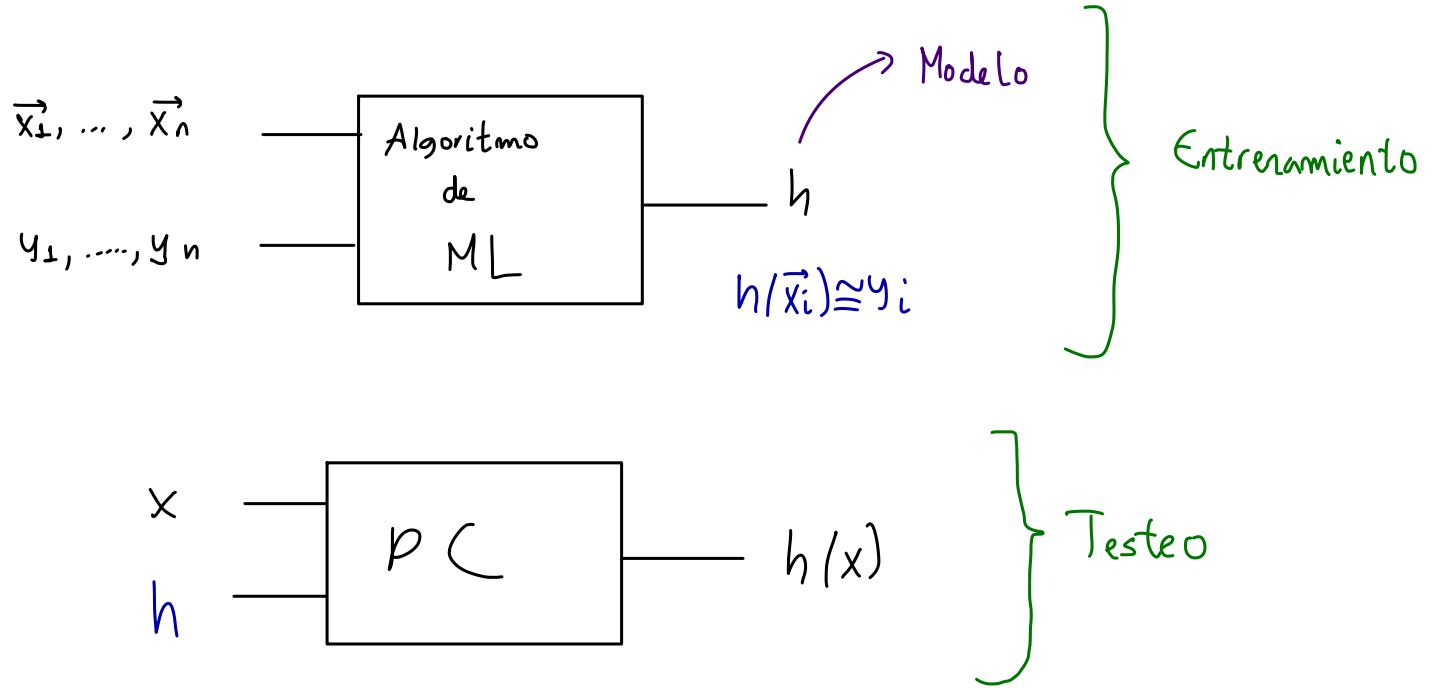
RGB

$$\vec{X}_i = \begin{bmatrix} 0.3 \\ 0.5 \\ 0.8 \\ \vdots \\ \vdots \end{bmatrix} \} \text{ primer pixel}$$

Entrenamiento y testeo



Entrenamiento y testeo



Observación: Más adelante veremos una fase adicional en el aprendizaje:
la validación

Funciones de pérdida "funcion de costo"

- Para h un modelo de ML de clasificación binaria $\{0,1\}$
 D un conjunto de datos

Función "0/1-Loss"

$$\mathcal{L}_{0/1}(h; D) = \frac{1}{n} \sum_{(\vec{x}_i, y_i) \in D} \delta_{h(\vec{x}_i) \neq y_i}$$

$$\delta_{h(\vec{x}_i) \neq y_i} = \begin{cases} 1 & \text{si } h(x_i) \neq y_i \\ 0 & \text{e.o.c.} \end{cases}$$

□ Para h un modelo de regresión

Función de pérdida cuadrática

$$\mathcal{L}(h; D) = \frac{1}{n} \sum_i (h(x_i) - y_i)^2$$

Función de pérdida absoluta

$$\mathcal{L}(h; D) = \frac{1}{n} \sum_i |h(x_i) - y_i|$$

Queremos que la función de pérdida sea baja en nuevos
datos que pongamos como entrada

Quisiéramos minimizar

$$E [\mathcal{L}(h; (\vec{x}, y))]_{(\vec{x}, y) \sim p}$$

Desconocemos la distribución.

No podemos minimizar

Podemos aproximar

