

Hoy: ☐ Regresión lineal


☐ Mínimos cuadrados (RSS)

☐ Decenso de gradiente


☐ Coeficiente de determinación

☐ Práctica linear regressor de Sklearn

Regresión lineal



Regresión lineal



Consiste en determinar un modelo lineal para describir o aproximar los datos

Consideremos un conjunto de datos con p atributos y una variable objetivo que denotaremos Y .

Usaremos X_1, X_2, \dots, X_p para denotar los p atributos

$$y \quad X = (X_1, X_2, \dots, X_p)^T$$

El modelo tendrá la forma

$$f(X) = \underbrace{\beta_0}_{\downarrow} + \sum_{j=1}^p X_j \underbrace{\beta_j}_{\swarrow}$$

parámetros

Regresión lineal

Consiste en determinar un modelo lineal para describir o aproximar los datos


Consideremos un conjunto de datos con p atributos y una variable objetivo que denotaremos Y .

Usaremos X_1, X_2, \dots, X_p para denotar los p atributos

$$y \quad X = (X_1, X_2, \dots, X_p)^T$$

El modelo tendrá la forma

$$f(X) = \underbrace{\beta_0 + \sum_{j=1}^p X_j \beta_j}_{\text{parámetros}}$$



Observación.

En ocasiones se designa $X_0 = 1$ \rightarrow vector de 1's y se expresa $f(X)$ con un sólo término

$$f(X) = \sum_{j=0}^p X_j \beta_j$$

$$f(X) = \underbrace{\beta_0}_{\downarrow} + \sum_{j=1}^p X_j \underbrace{\beta_j}_{\swarrow}$$

parámetros

¿Cómo estimar los parámetros β_i ?

Dado un conjunto de datos


$$D = (\vec{x}_1, y_1) \dots (\vec{x}_N, y_N)$$

Se quisiera minimizar la

Suma Residual de Cuadrados

$$RSS(\beta) = \sum_{i=1}^N (y_i - f(x_i))^2$$


$$= \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^p x_{ij} \beta_j \right)$$



$$RSS(\beta) = \sum_{i=1}^N (y_i - f(x_i))^2$$

Sea X la matriz

N registros



columna atributo 1

atributo N

Tamaño
 $N \times (p+1)$

y sea \vec{y} el vector de salidas en el conjunto de entrenamiento

$$RSS(\beta) = (\vec{y} - X \vec{\beta})^T (\vec{y} - X \vec{\beta})$$

$$RSS(\beta) = (\vec{y} - X\vec{\beta})^T (\vec{y} - X\vec{\beta})$$

Esta es una función cuadrática en los parámetros β_0, \dots, β_p .
Si derivamos con respecto a los β_i obtenemos

$$\frac{\partial RSS}{\partial \beta} = -2 X^T (\vec{y} - X\vec{\beta})$$

$$\frac{\partial^2 RSS}{\partial \beta \partial \beta^T} = 2 X^T X$$

Si X tiene rango completo entonces $X^T X$ es semidefinida positiva
y el mínimo se encontraría igualando la primera derivada a cero

$$X^T (\vec{y} - X\vec{\beta}) = 0 \quad \hat{\beta} = (X^T X)^{-1} X^T \vec{y}.$$

El método anterior nos provee de una solución matemática precisa para estimar el vector de parámetros $\vec{\beta}$.

Pero.... es computacionalmente costoso

¿Otra opción?

Descenso de gradiente

Un método, en este caso computacionalmente menos costoso para optimizar RSS, y en general muy utilizado en ML incluyendo las redes neuronales

Queremos minimizar:

$$RSS(\beta) = \sum_{i=1}^N \left(y_i - \beta_0 - \sum_{j=1}^P x_{ij} \beta_j \right)$$

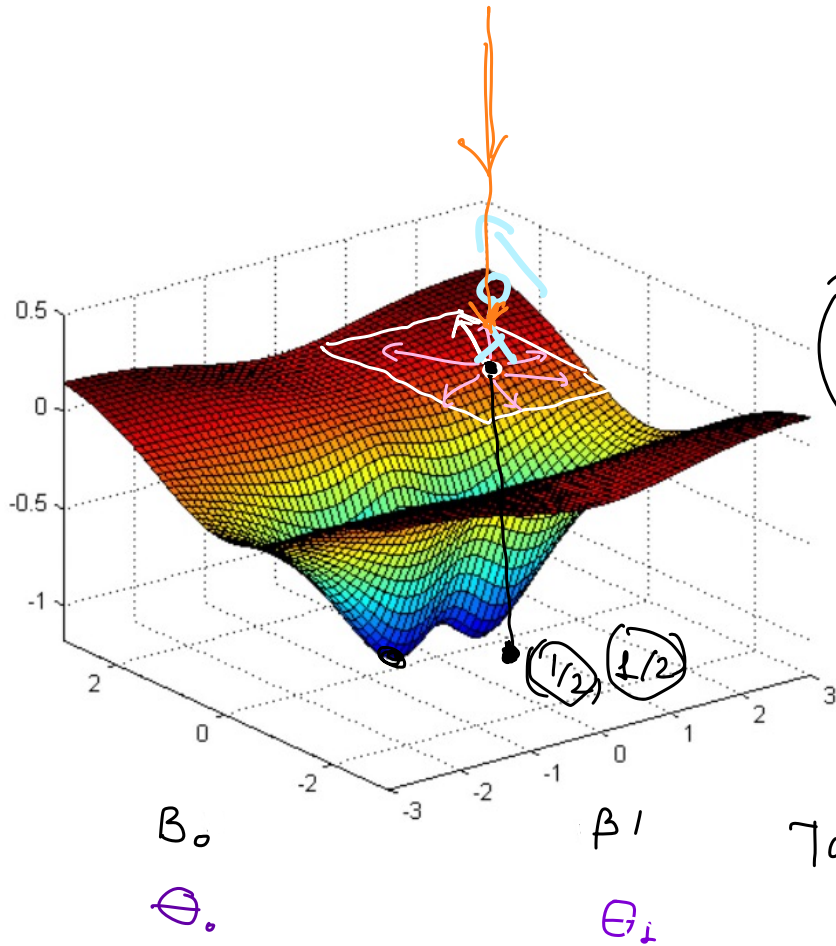
Ejemplo $P=1$

$$RSS(\beta) = \sum_{i=1}^N y_i - \underbrace{\beta_0}_{\text{ }} - x_{i1} \underbrace{\beta_1}_{\text{ }}$$

Das variables!

Una función continua de dos variables se puede imaginar como
una superficie

RSS
 $J(\theta_0, \theta_1)$




$$J(\theta_0, \theta_1) | (3, -10)$$


$$\nabla J(\theta_0, \theta_1) = \left(\frac{\partial J}{\partial \theta_0}, \frac{\partial J}{\partial \theta_1} \right)$$

Damos un paso
 en dirección opuesta
 al gradiente

Tamaño del paso α
 learning rate



Una vez tenemos el modelo




¿Cómo podemos medir qué tan bueno es?


Coefficiente de determinación R^2

Sirve para medir qué tanto la variable dependiente es explicada por la(s) variable(s) independiente(s).

¿Cómo se mide? consideremos los cuadrados de las diferencias en 2 escenarios:



$$RSS = \sum_{i=1}^N (y_i - f(x_i))^2$$



$$SS(\text{mean}) = \sum_{i=1}^N (y_i - \bar{y})^2$$

R^2 compara qué tanto disminuye el error nuestro modelo con respecto al modelo horizontal \bar{y} .

$$R^2 = 1 - \frac{RSS}{SS(\text{mean})}$$

$$R^2 = \frac{SS(\text{mean}) - RSS}{SS(\text{mean})}$$

$$0 \leq R^2 \leq 1$$