




Máquinas de soporte vectorial



Máquinas de soporte vectorial



→ Paralelas!


Cuál es mejor entre las 3 rectas para clasificar estos datos?

Separarlos mientras se maximiza d


→ Distancia al punto más cercano

Margen

A veces se considera sólo la mitad




Cuál es mejor
según un clasificador
de soporte vectorial?



→ Se prioriza la margen máxima

Matemáticamente hablando, cómo se determina la recta?



Matemáticamente hablando, cómo se determina la recta?

Si restamos las dos
ecuaciones que satisfacen x_1 y x_2 :

$$w^T x_1 + b = 1$$


$$w^T x_2 + b = -1$$

$$w^T (x_2 - x_1) = 2$$

dividimos entre $\|w\|$

$$\frac{w^T (x_2 - x_1)}{\|w\|} = \frac{2}{\|w\|}$$

Vector
a maximizar



Matemáticamente hablando, cómo se determina la recta?

Si restamos las dos ecuaciones que satisfacen x_1 y x_2 :

$$w^T x_1 + b = 1$$


$$w^T x_2 + b = -1$$

$$w^T (x_2 - x_1) = 2$$

dividimos entre $\|w\|$

$$\frac{w^T (x_2 - x_1)}{\|w\|} = \frac{2}{\|w\|}$$

proyección de $x_2 - x_1$ sobre w . Luego esta es la medida a maximizar, la cual es igual a $\frac{2}{\|w\|}$



$$\text{proy}_{\vec{w}} \vec{v} = \frac{\vec{v} \cdot \vec{w}}{\|\vec{w}\|} \vec{w}$$

ojo! w es perpendicular a la recta/plano/hiperplano

Matemáticamente hablando, cómo se determina la recta?

Si restamos las dos ecuaciones que satisfacen x_1 y x_2 :

$$w^T x_1 + b = 1$$

$$w^T x_2 + b = -1$$


$$w^T (x_2 - x_1) = 2$$

dividimos entre $\|w\|$

$$\boxed{\frac{w^T (x_2 - x_1)}{\|w\|}} = \boxed{\frac{2}{\|w\|}}$$

→ proyección de $x_2 - x_1$ sobre w . Luego esta es la medida a maximizar

Magnitud a maximizar



$$\text{proy}_{\vec{w}} \vec{v} = \frac{\vec{v} \cdot \vec{w}}{\|\vec{w}\|} \vec{w}$$

¡ojo! w es perpendicular al (hyper)plano/recta

Maximizar $\frac{2}{\|w\|}$, equivalente a minimizar $\|w\|^2$ (*)

Obs A la vez que maximizamos el margen, quisiéramos que los puntos queden bien clasificados

¿Qué quiere decir bien clasificados (por el modelo lineal)?

ojo

Aquí usamos
las etiquetas
 $\{-1, 1\}$ en lugar
de $\{0, 1\}$

$$y_i (w^T x_i - b) \geq 1 \quad (**)$$

Diagram illustrating the classification constraint for two classes:

- For $y_i = 1$, the constraint is $w^T x_i - b \geq 1$.
- For $y_i = -1$, the constraint is $w^T x_i - b \leq -1$.

Casos en que
el punto está
bien clasificado

Finalmente, para encontrar los parámetros de la mejor recta/plano/hiperplano, se minimiza la siguiente expresión

$$\min_{\mathbf{w}} \quad C \|\mathbf{w}\|^2 + \left[\frac{1}{n} \sum_{i=1}^n \max \{0, 1 - y_i (\mathbf{w}^T \mathbf{x}_i - b)\} \right]$$

Finalmente, para encontrar los parámetros de la mejor recta/plano/hiperplano, se minimiza la siguiente expresión

$$\min \quad C \|w\|^2 + \left[\frac{1}{n} \sum_{i=1}^n \max \{0, 1 - y_i(w^T x_i - b)\} \right]$$

]


hiperparámetro

maximizando
el margen

maximizando la
cantidad de puntos
bien clasificados

establece equilibrio entre
mayor margen y
puntos bien clasificados

Datos no separables linealmente





Datos no separables linealmente

podemos agregar una dimension/atributo

$$(x_1, x_2, x_3)$$

$$x_3 = x_1^2 + x_2^2$$

$$"z = x^2 + y^2"$$



Ahora se pueden separar por un plano


Datos no separables linealmente

podemos agregar una dimension/atributo


$$(x_1, x_2, x_3)$$

$$x_3 = x_1^2 + x_2^2$$


$$z = x^2 + y^2$$




??



Ahora se pueden separar por un plano






Cuál atributo
agregaría?

x →	<div></div>
y →	
? →	

Kernels

Los Kernel nos dan diferentes formas de involucrar un aumento en la dimensionalidad de los datos en el problema de optimización



Queríamos optimizar el problema siguiente

$$\text{Minimizar} \quad C \|w\|^2 + \left[\frac{1}{n} \sum_{i=1}^n \max \{0, 1 - y_i (w^T x_i - b)\} \right]$$

Este problema equivale al siguiente (programación cuadrática)

Expresa "similitud" entre pares de vectores

Nuevo vector de parámetros

$$\text{Maximizar} \quad W(\alpha) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \underbrace{x_i^T x_j}_{K(x_i, x_j)}$$

+ q. $\alpha_i \geq 0 \quad \sum \alpha_i y_i$

Esta similitud o relación entre vectores se puede expresar de diferentes formas

Algunos tipos de Kernel

Polinomial: $(x^T y + r)^d$ si $r=0$, $d=1$, corresponde al "Kernel lineal"

Radial: $e^{-\gamma \|\vec{x} - \vec{y}\|^2}$ RBF (Radial basis function)

Tang. hiperbólica: $\tanh(\alpha x^T y + \theta)$



Algunos tipos de kernel

$a, b \in \mathbb{R}$

Ejemplo con el polinomial: $(a \cdot b + r)^d$

Ejemplo $r = \frac{1}{2}$
 $d = 2$

$$\begin{aligned} \left(a \cdot b + \frac{1}{2} \right)^2 &= \left(ab + \frac{1}{2} \right) \left(ab + \frac{1}{2} \right) \\ &= ab + a^2 b^2 + \frac{1}{4} \\ &= \left(a, a^2, \frac{1}{2} \right) \left(b, b^2, \frac{1}{2} \right) \end{aligned}$$



Radial : $e^{-\gamma \|\vec{x} - \vec{y}\|^2}$

El kernel radial permite un incremento hacia una dimensionalidad infinita, por medio de la expresión en serie de Taylor de la función e^x

$$e^x = 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + \frac{x^4}{4!} + \dots$$

para detalles recomiendo el video de Josh Starmer (Statquest)

"Support Vector machines
Part 3: The radial (RBF)
kernel"

En dimensiones finitas, el kernel radial tiene en cuenta la distancia entre vectores; $e^{-\gamma \|\vec{x} - \vec{y}\|^2}$
por lo que puede clasificarse de forma similar a KNN (weighted)

Algunos parámetros de SVM en sklearn

Kernel: Linear, ^{radial} rbf, etc

C: parámetro en la ecuación: $C \|w\|^2 + \left[\frac{1}{n} \sum_{i=1}^n \max \{0, 1 - y_i (w^T x_i - b)\} \right]$

establece un equilibrio entre maximizar el margen y clasificar bien los puntos

γ : Determina qué tan lejana es la influencia de un punto de entrenamiento mediante peso que se le da a las distancias

valores bajos - alcance lejano

valores altos - alcance cercano

