


Dimensión VC

Se puede considerar como una métrica de la complejidad de un algoritmo de ML.


Consideremos un algoritmo de clasificación binaria.




Llamemos \mathcal{H} al conjunto de todos los posibles modelos arrojados por el algoritmo. ^{"espacio de hipótesis"}

ej. **todas** las rectas en \mathbb{R}^2

Sea X el espacio de instancias a clasificar.




Consideremos un subconjunto de instancias $S \subseteq X$.




Cada modelo h separa el conjunto S en dos subconjuntos.
En otras palabras, cada modelo genera una dicotomía en el conjunto S .

\in_j




Diremos entonces que h "representa" dicha dicotomía.


Ahora, dada cualquier dicotomía en S



podemos preguntarnos si hay un modelo h que la representa



?




para ésta
sí!

Siempre la hay?

NO!

hay algún conjunto S para el cual
toda dicotomía tenga un modelo
que la represente?




En este caso, decimos que H separa al conjunto de tres puntos de arriba

Se puede para 4? \mathcal{H} separa al conjunto?





X

X



X

X



¿ Algún conjunto
de 4 puntos
se puede separar
por H ?

El conjunto

x	x
x	x

No se puede "separar" por H


Ningún conjunto de 4 puntos se puede separar por H !

Decimos entonces que la Dimensión VC de H es 3

Definición formal

Un algoritmo de clasificación binaria genera una familia \mathcal{F} de subconjuntos del espacio X de instancias.


$$\mathcal{F} = \{F_1, F_1^c, F_2, F_2^c, \dots\}$$



Definición Una familia \mathcal{F} de subconjuntos separa (atomiza)

un conjunto $S = \{s_1, \dots, s_n\}$ si

$$\forall x \in S, \exists F_i \in \mathcal{F} \quad x = F_i \cap S$$



Definición La dimensión VC de una familia \mathcal{F} es el máximo número D tal que existe un conjunto S de tamaño D tal que \mathcal{F} separa a S . Si no existe un máximo, entonces la dimensión es ∞ .

La dimensión VC de un algoritmo de clasificación es la dimensión VC de su familia \mathcal{F} asociada.

Observaciones

- La dimensión VC en general es difícil de calcular!
- Si la dimensión VC es grande, el algoritmo es más complejo (y más propenso al sobreajuste)

Ejercicio

¿Cuál es la dimensión VC de la familia de planos en \mathbb{R}^3 ?

Ejercicio

Generalización a hiperplanos: demostrar que la dimensión VC de los hiperplanos en \mathbb{R}^n es $n+1$

Ejercicio

La dimensión VC de una familia finita \mathcal{F} es a lo más $\log_2 |\mathcal{F}|$ ¿Por qué?

Dimensión VC en Máquinas de soporte vectorial

Con Kernel lineal \equiv hiperplanos ($VC\text{-dim} = n+1$)

Con Kernel RBF : $VC\text{-dim} = \infty$

Dimensión VC en redes neuronales

Si E es el conjunto de aristas de una red neuronal y V es el conjunto de vértices (Nodos), entonces:

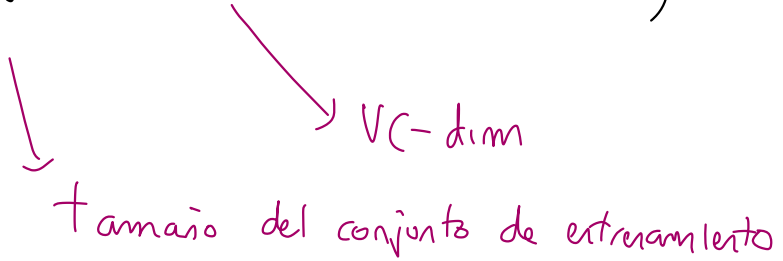
Si la función de activación es la función de salto (step function)
$$VC\text{-dim} \leq O(|E| \cdot \log |E|)$$

Si la activación es la sigmoide $VC\text{-dim} \leq O(|E|^2, |V|^2)$

Si los pesos vienen de una familia finita, $VC\text{-dim} \leq O(E)$
(para ambas activaciones)

Una cota para el error de testeo

$$P(\text{test error} \leq \text{training error} + \sqrt{\frac{1}{N} \left[D \left(\log \left(\frac{2N}{D} \right) + 1 \right) - \log \left(\frac{\alpha}{4} \right) \right]}) = 1 - \alpha$$


The diagram shows two arrows originating from the term $D \left(\log \left(\frac{2N}{D} \right) + 1 \right)$ in the equation above. One arrow points from D down to the text 'tamaño del conjunto de entrenamiento'. The other arrow points from $\log \left(\frac{2N}{D} \right)$ down to the text 'VC-dim'.